

Aprendizado de Máquinas

Aula 01 – Visão Geral de Aprendizado de Máquinas



UNICAMP

Marcos Eduardo Valle
Matemática Aplicada
IMECC - Unicamp



Introdução

Aprendizado de Máquina (Aurélien Géron, 2019)

Aprendizado de máquina é a ciência (e a arte) de programar computadores para que eles aprendam com os dados.

Aprendizado de Máquina (Tom Mitchell, 1997)

Diz-se que um programa de computador aprende com a experiência $\mathcal{E}$ em relação a alguma tarefa $\mathcal{T}$ e alguma medida de desempenho $\mathcal{P}$, se seu desempenho em $\mathcal{T}$, como medida por $\mathcal{P}$, melhora com a experiência $\mathcal{E}$.

Exemplo 1 (Detecção de SPAM)

Considere a tarefa $\mathcal{T}$ de classificar emails como regular ou SPAM. A experiência $\mathcal{E}$ é um conjunto de emails rotulados como regular ou SPAM, conhecidos como *conjunto de treino*. A medida do desempenho $\mathcal{P}$ pode ser a *acurácia*, ou seja, a proporção de emails identificados corretamente como regular ou SPAM.

A tarefa de detecção de SPAM é um exemplo de um problema de classificação binária e foi apresentada como um problema de aprendizado de máquina supervisionado.

Técnicas de aprendizado de máquina também podem ser usadas para destacar ou estabelecer correlações e tendências no contexto da mineração de dados.

De um modo geral, as técnicas de aprendizado de máquina podem ser classificadas de acordo com os seguintes critérios:

- Tipo do treinamento: Supervisionado, não-supervisionado, semi-supervisionado, etc.
- Modo do treinamento: Incremental (online) ou não.

Nosso foco nessa disciplina será no aprendizado supervisionado não-incremental, incluindo problemas de classificação e regressão. Porém, veremos também algumas técnicas que não são supervisionadas como redução de dimensionalidade e agrupamento, que são classificadas como não-supervisionadas.

É frequentemente recomendado aplicar redução de dimensionalidade antes de usar um algoritmo de aprendizado de máquina, reduzindo assim o armazenamento em disco e memória e eventualmente melhorando o desempenho do algoritmo!

Desafios no Aprendizado de Máquinas

De um modo geral, num problema prático devemos escolher o modelo e o conjunto de dados de treinamento.

Além de evitar erros, ruído e *outliers*, é essencial que o conjunto de dados seja representativo para novas situações! Chamamos “*viés de amostragem*” quando o conjunto de dados não é representativo o suficiente para novos casos.

A escolha do modelo deve ser cuidadosa para evitar subajuste ou sobreajuste. Com efeito, modelos simples tendem a subajustar os dados enquanto modelos complexos tendem sobreajustar os dados de treinamento.

O sobreajuste ocorre quando o modelo é muito complexo em relação à quantidade e ruído dos dados de treinamento. Soluções possíveis para o sobreajuste incluem:

- Simplifique o modelo selecionando um com menos parâmetros (por exemplo, um modelo linear em vez de um modelo polinomial de alto grau), reduzindo o número de atributos nos dados de treinamento ou restringindo o modelo.
- Reúna mais dados de treinamento.
- Reduza o ruído nos dados de treinamento (por exemplo, corrija erros de dados e remova outliers).

Técnicas de *regularização* são muito utilizadas atualmente para evitar o sobreajuste.

Treino, Validação e Teste

Para determinar se um modelo sairá bem em novos dados é comum dividir o conjunto de dados em dois ou três subconjuntos como segue:

- **Treinamento:** O conjunto de treinamento é usado para ajustar os parâmetros do modelo.
- **Validação:** É geralmente usado para ajustar os hiper-parâmetros do modelo.
- **Teste:** É usado para avaliar a capacidade de generalização do modelo para dados novos.

Um modelo é uma representação simplificada dos dados. As simplificações devem descartar detalhes supérfluos que provavelmente não generalizarão para novas instâncias. Ao selecionar um determinado tipo de modelo, você implicitamente fazendo suposições sobre os dados.

Por exemplo, se você escolher um modelo linear, você está assumindo implicitamente que os dados são fundamentalmente linear e que a distância entre as instâncias e a linha reta é apenas ruído, que pode ser ignorado com segurança.

No Free Lunch Theorem (David Wolpert, 1996)

Se você fizer absolutamente nenhuma suposição sobre os dados, então não há razão para preferir um modelo sobre qualquer outro.

Em outras palavras, não existe um modelo que seja a priori garantido para funcionar melhor.

Considerações Finais

Na aula de hoje, apresentamos alguns dos conceitos sobre aprendizado de máquina.

Destacamos, em particular, que os algoritmos de aprendizado de máquina aprendem com dados. Nesse contexto, é importante escolher um bom conjunto de dados e também um bom modelo.

Para verificar a capacidade de generalização, geralmente dividimos o conjunto de dados em conjuntos de treino e teste.

O conjunto de treino pode ser também subdividido para ajuste dos hiperparâmetros e, nesse caso, pode ser referido como conjunto de validação.

Muito grato pela atenção!