


Aprendizado de Máquinas

Aula 02 – Regressão Linear e Ajuste de Curvas



UNICAMP

Marcos Eduardo Valle
Matemática Aplicada
IMECC - Unicamp



Introdução

A regressão linear é um dos modelos mais simples e serve de base para compreender modelos mais elaborados como as redes neurais artificiais.

Um modelo linear define faz uma previsão $\hat{y}$ através da equação

$$\hat{y} = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n, \quad (1)$$

em que $\theta_0, \theta_1, \dots, \theta_n \in \mathbb{R}$ são os parâmetros do modelo e $x_1, \dots, x_n$ são as características (componentes) da entrada.

Os termos $\theta_1, \dots, \theta_n$ são também chamados pesos enquanto θ_0 é referido como bias ou intercepto.

Formalmente, um modelo linear define uma função $h_{\theta} : \mathbb{R}^n \rightarrow \mathbb{R}$, chamada função de hipótese, dada pela equação

$$h_{\theta}(\mathbf{x}) = \theta_0 + \sum_{j=1}^n \theta_j x_j, \quad (2)$$

em que $\mathbf{x} = (x_1, x_2, \dots, x_n)$ é o vetor de entrada.

De forma alternativa, podemos escrever

$$h_{\theta}(\mathbf{x}) = \bar{\mathbf{x}}^T \theta, \quad (3)$$

em que $\theta = (\theta_0, \theta_1, \dots, \theta_n) \in \mathbb{R}^{n+1}$ é o vetor de parâmetros e $\bar{\mathbf{x}} = (x_0, x_1, \dots, x_n) \in \mathbb{R}^{n+1}$ é o vetor de entrada aumentado com $x_0 = 1$.

Treinamento de um Modelo Linear

Um conjunto de treino $\mathcal{T} = \{(\mathbf{x}_i, y_i) : i = 1, \dots, m\} \subset \mathbb{R}^n \times \mathbb{R}$ pode ser utilizado para determinar o vetor de parâmetros θ de um modelo linear minimizando uma função perda, tal como a média do quadrado dos erros (MSE, *mean squared error*).

O MSE de uma função de hipótese h_θ sobre um conjunto de treinamento $\mathcal{T}$ é dado pela equação:

$$\text{MSE}(\mathcal{T}, h_\theta) = \frac{1}{m} \sum_{i=1}^m (h_\theta(\mathbf{x}_i) - y_i)^2. \quad (4)$$

Durante o treinamento, determinamos o vetor de parâmetros θ que minimiza o MSE. Nesse contexto, é comum escrever $\text{MSE}(\theta)$ em vez de $\text{MSE}(\mathcal{T}, h_\theta)$.

Solução do Problema de Quadrados Mínimos

Quando a função de hipótese é linear, a solução do problema

$$\underset{\boldsymbol{\theta} \in \mathbb{R}^{n+1}}{\text{minimize}} \text{MSE}(\boldsymbol{\theta}) \equiv \underset{\boldsymbol{\theta} \in \mathbb{R}^{n+1}}{\text{minimize}} \frac{1}{m} \sum_{i=1}^m (h_{\boldsymbol{\theta}}(\mathbf{x}_i) - y_i)^2, \quad (5)$$

é dada por

$$\boldsymbol{\theta}^* = \mathbf{X}^\dagger \mathbf{y}, \quad (6)$$

em que

$$\mathbf{X} = \begin{bmatrix} \bar{\mathbf{x}}_1^T \\ \vdots \\ \bar{\mathbf{x}}_m^T \end{bmatrix} \in \mathbb{R}^{m \times (n+1)} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} \in \mathbb{R}^m$$

são obtidos organizado o conjunto de dados numa matriz $\mathbf{X}$ e num vetor $\mathbf{y}$, e $\mathbf{X}^\dagger$ denota a pseudo-inversa (ou inversa generalizada de Moore-Penrose) de $\mathbf{X}$ (Golub and van Loan, 1996).

Se a matriz $\mathbf{X} \in \mathbb{R}^{m \times (n+1)}$ tem posto completo, sua pseudo-inversa satisfaz a equação (Trefethen and Bau III, 1997):

$$\mathbf{X}^\dagger = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \in \mathbb{R}^{(n+1) \times m}. \quad (7)$$

A pseudo-inversa de $\mathbf{X}$ pode ser calculada no `python` usando a biblioteca `numpy` com o comando:

```
»np.linalg.pinv(X)
```

A complexidade computacional para o cálculo do vetor de parâmetros θ é $\mathcal{O}(mn^2 + n^3)$.


- O cálculo se torna lento quando há um número elevado de características (n grande).
- Ele é linear com respeito ao número de amostras m e, portanto, conseguimos trabalhar com conjuntos de dados grandes.

Exemplo

O gráfico abaixo apresenta o diagrama de dispersão de um conjunto de pontos obtidos pela equação

$$y = 4 + 3x + \epsilon, \quad (8)$$

em que $\epsilon \sim \mathcal{N}(0, 1)$ (distribuição normal com $\mu = 0$ e $\sigma^2 = 1$).



Treinando o modelo linear, encontramos encontramos a reta vermelha cujos parâmetros são $\theta_0 = 4.215$ e $\theta_1 = 2.770$.

Ajuste de Curvas

A regressão linear pode ser utilizada em contextos mais gerais para o ajuste de curvas em que a dependência nos parâmetros é linear.

Especificamente, podemos considerar uma função hipótese $h_{\theta} : \mathcal{X} \rightarrow \mathbb{R}$ dada por

$$h_{\theta}(\mathbf{x}) = \theta_0 + \sum_{j=1}^n \theta_j g_j(\mathbf{x}) \equiv \bar{\mathbf{g}}^T(\mathbf{x})\theta, \quad (9)$$

em que $g_1, g_2, \dots, g_n : \mathcal{X} \rightarrow \mathbb{R}$ são funções base definidas *a priori* e possivelmente não-linear nas características $\mathbf{x}$.

Note que (9) pode ser interpretada como a regressão linear aplicada em dados pré-processados por uma função $\bar{\mathbf{g}} : \mathcal{X} \rightarrow \mathbb{R}^{n+1}$ que transforma a entrada $\mathbf{x}$ em $(1, g_1(\mathbf{x}), \dots, g_n(\mathbf{x}))$.

Nesse caso, a solução do problema do problema

$$\underset{\boldsymbol{\theta} \in \mathbb{R}^{n+1}}{\text{minimize}} \text{MSE}(\boldsymbol{\theta}) \equiv \underset{\boldsymbol{\theta} \in \mathbb{R}^{n+1}}{\text{minimize}} \frac{1}{m} \sum_{i=1}^m (h_{\boldsymbol{\theta}}(\mathbf{x}_i) - y_i)^2, \quad (10)$$

é

$$\boldsymbol{\theta}^* = \mathbf{G}^\dagger \mathbf{y}, \quad (11)$$

em que

$$\mathbf{G} = \begin{bmatrix} \bar{\mathbf{g}}^T(\mathbf{x}_1) \\ \vdots \\ \bar{\mathbf{g}}^T(\mathbf{x}_m) \end{bmatrix} \in \mathbb{R}^{m \times (n+1)} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} \in \mathbb{R}^m.$$

Sobretudo, a função de hipótese $h_{\boldsymbol{\theta}}$ pode resultar em modelos complexos que ajustam perfeitamente o conjunto de dados de treinamento. Porém, não há garantias de produzir um resultado melhor para dados que não foram usados no treinamento.

Regressão Polinomial

Na regressão polinomial, a função hipótese h_{θ} é um polinômio nas características $\mathbf{x}$, mas é linear nos parâmetros θ .

A regressão polinomial é obtida considerando polinômios independentes como funções base $g_1, \dots, g_n$.

Exemplo 1

As funções base $g_1(x) = x$ e $g_2(x) = x^2$ resultam na função


$$\bar{\mathbf{g}}(x) = (1, x, x^2),$$

que pode ser usada para ajustar uma parábola à um conjunto de dados $\mathcal{T} = \{(x_i, y_i) : i = 1, \dots, m\} \subseteq \mathbb{R} \times \mathbb{R}$.

Exemplo

O gráfico abaixo apresenta o diagrama de dispersão de um conjunto de pontos obtidos pela equação

$$y = \frac{1}{2}x^2 + x + 2 + \epsilon, \quad \text{com } \epsilon \sim \mathcal{N}(0, 1). \quad (12)$$



Treinando o modelo $h_{\theta}(x) = \bar{\mathbf{g}}^T(x)\theta$, encontramos encontramos a curva vermelha cujo vetor de parâmetros é $\theta = (1.78, 0.93, 0.56)$.

Considerações Finais

Na aula de hoje, tratamos o problema de regressão linear, cuja função de hipótese é dada por $h_{\theta}(\mathbf{x}) = \mathbf{x}^T \theta$.

Dado um conjunto de treinamento $\mathcal{T} = \{(\mathbf{x}_i, y_i) : i = 1, \dots, m\}$, o vetor de parâmetros pode ser determinado minimizando o erro quadrático médio (MSE) como segue:

$$\underset{\theta \in \mathbb{R}^{n+1}}{\text{minimize}} \frac{1}{m} \sum_{i=1}^m (h_{\theta}(\mathbf{x}_i) - y_i)^2. \quad (13)$$

Finalmente, a solução do problema de otimização pode ser obtida usando a pseudo-inversa.

Muito grato pela atenção!

References (1)

- G. H. Golub and C. F. van Loan. *Matrix Computations*. John Hopkins University Press, Baltimore, MD, 3th edition, 1996.
- L. N. Trefethen and D. Bau III. *Numerical Linear Algebra*. SIAM Publications, Philadelphia, PA, 1997.