

# Aprendizado de Máquinas

## Aula 05 – Regressão Linear Regularizada



**UNICAMP**

Marcos Eduardo Valle  
Matemática Aplicada  
IMECC - Unicamp



# Introdução

---

De um modo geral, as técnicas de regularização adicionam restrições nos parâmetros treináveis.

---

Como consequência, as técnicas de regularização tendem à reduzir o sobre-treinamento (*overfitting*) de um modelo de aprendizado de máquina.

---

Na aula de hoje veremos técnicas de regularização para modelos lineares descritos pela equação

$$h_{\theta}(\mathbf{x}) = \theta_0 + \sum_{j=1}^n \theta_j x_j, \quad (1)$$

em que  $\mathbf{x} = (x_1, x_2, \dots, x_n)$  é o vetor de características e  $\theta = (\theta_0, \theta_1, \dots, \theta_n) \in \mathbb{R}^{n+1}$  são os parâmetros treináveis ou pesos do modelo.

# Regressão Ridge

---

A regressão ridge utiliza a chamada regularização de Tikhonov, que consiste em adicionar ao MSE o termo

$$\mathcal{R}_2(\boldsymbol{\theta}) = \alpha \sum_{j=1}^n \theta_j^2, \quad \alpha \geq 0. \quad (2)$$

---

Dessa forma, dado um conjunto de treinamento

$\mathcal{T} = \{(\mathbf{x}_i, y_i) : i = 1, \dots, m\} \subset \mathbb{R}^n \times \mathbb{R}$ , a regressão ridge minimiza a função perda

$$\mathcal{L}(\boldsymbol{\theta}) = \text{MSE}(\boldsymbol{\theta}) + \mathcal{R}_2(\boldsymbol{\theta}) \equiv \frac{1}{m} \sum_{i=1}^m (h_{\boldsymbol{\theta}}(\mathbf{x}_i) - y_i)^2 + \alpha \sum_{j=1}^n \theta_j^2. \quad (3)$$

---

Note que o viés  $\theta_0$  não contribui para o termo de regularização!

O parâmetro  $\alpha \geq 0$  controla o quanto o modelo é regularizado.

1. Por um lado, temos a regressão linear usual quando  $\alpha = 0$ .
2. Por outro lado, os parâmetros  $\theta_1, \dots, \theta_n$  tendem a zero quando  $\alpha$  é suficientemente grande e o modelo linear resulta na média dos  $y_1, \dots, y_m$  usados no treinamento.

---

O valor mínimo da função perda da regressão ridge pode ser obtido usando métodos baseados no gradiente ou usando as equações normais (quadrados mínimos tradicional).

---

Em particular, usando as equações normais, o mínimo da função perda da regressão ridge é obtido em

$$\theta^* = \frac{1}{m} \left( \frac{1}{m} \mathbf{X}^T \mathbf{X} + \alpha \mathbf{A} \right)^{-1} \mathbf{X}^T \mathbf{y}, \quad (4)$$

em que  $\mathbf{A} = \begin{bmatrix} \mathbf{0}_{1 \times 1} & \mathbf{0}_{1 \times n} \\ \mathbf{0}_{n \times 1} & \mathbf{I}_{n \times n} \end{bmatrix} \in \mathbb{R}^{(n+1) \times (n+1)}$ .

# Regressão Lasso

---

A regressão lasso, do inglês *least absolute shrinkage and selection operator*, é obtida adicionado ao MSE a soma dos valores absolutos dos parâmetros  $\theta_1, \dots, \theta_n$ .

---

Em termos matemáticos, a regressão lasso contém o termo de regularização dado por

$$\mathcal{R}_1(\boldsymbol{\theta}) = \alpha \sum_{j=1}^n |\theta_j|. \quad (5)$$

---

A regressão lasso tende à eliminar os parâmetros associados às características menos importantes. Dessa forma, ela pode ser usada para seleção de características.

Dado um conjunto de treinamento  $\mathcal{T} = \{(\mathbf{x}_i, y_i) : i = 1, \dots, m\}$ , os parâmetros da regressão lasso são determinados minimizando a função perda

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{2} \text{MSE}(\boldsymbol{\theta}) + \mathcal{R}_1(\boldsymbol{\theta}) \equiv \frac{1}{2m} \sum_{i=1}^m (h_{\boldsymbol{\theta}}(\mathbf{x}_i) - y_i)^2 + \alpha \sum_{j=1}^n |\theta_j|. \quad (6)$$

---

Diferente da regressão ridge, a função perda da regressão lasso é não diferenciável em  $\theta_j = 0$ , para  $j = 1, \dots, n$ .

---

Contudo, a função perda ainda é convexa e, portanto, métodos de otimização convexa podem ser aplicados para encontrar o mínimo da função perda em (6).

---

Em particular, o método do gradiente descendente estocástico pode ser aplicado para minimizar (6) substituindo o gradiente pelo sub-gradiente de da função perda.

Resumidamente, um vetor  $\mathbf{g}$  é um sub-gradiente de uma função  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  em  $\mathbf{x}$  se

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \mathbf{g}^T(\mathbf{y} - \mathbf{x}), \quad \forall \mathbf{y}. \quad (7)$$

---

Se  $f$  é convexa e diferenciável, então  $\nabla f(\mathbf{x})$  é um sub-gradiente de  $f$  em  $\mathbf{x}$  (Grant et al., 2006). Porém, o sub-gradiente de uma função convexa está bem definido mesmo quando ela não é diferenciável em  $\mathbf{x}$ .

---

O sub-gradiente da função perda da regressão lasso é

$$\nabla \mathcal{L}(\boldsymbol{\theta}) = \nabla \text{MSE}(\boldsymbol{\theta}) + \alpha \text{sign}(\boldsymbol{\theta}), \quad (8)$$

em que  $\text{sign}(\boldsymbol{\theta})$  é definida componente-à-componente com

$$\text{sign}(\theta_j) = \begin{cases} -1, & \theta_j < 0, \\ 0, & \theta_j = 0, \\ +1, & \theta_j > 0. \end{cases}$$

# Elastic Net

---

A Elastic Net combina os termos de regularização da regressão lasso e ridge, resultando na função perda

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{2} \text{MSE}(\boldsymbol{\theta}) + r\mathcal{R}_1(\boldsymbol{\theta}) + \frac{1}{2}(1-r)\mathcal{R}_2(\boldsymbol{\theta}) \quad (9)$$

$$\equiv \frac{1}{2m} \sum_{i=1}^m (h_{\boldsymbol{\theta}}(\mathbf{x}_i) - y_i)^2 + r\alpha \sum_{j=1}^n |\theta_j| + (1-r)\frac{\alpha}{2} \sum_{j=1}^n \theta_j^2, \quad (10)$$

para  $\alpha \geq 0$  e  $0 \leq r \leq 1$ .

---

Note que temos a regressão ridge quando  $r = 0$  e a regressão lasso quando  $r = 1$ .




Tal como a regressão lasso, a elastic net pode ser usada para a seleção de características.

---

Além disso, a elastic net pode apresentar resultados melhores que a regressão lasso quando o número de características é maior que o número de amostras ( $n > m$ ) ou existem muitas características fortemente relacionadas.

# Exemplo

A figura abaixo apresenta um conjunto de dados que foi dividido em subconjuntos de treino (azul) e teste (laranja).



O conjunto de treino foi usado para ajustar um polinômio de grau 10.

# Exemplo

---

Usando a regressão linear tradicional e os modelos regularizados, regressão ridge, regressão lasso e elastic net, encontramos os seguintes polinômios:

- **Regressão linear tradicional:**

$$p_{10}^{(T)}(x) = 0.49 + 2.12x + 3.39x^2 - 1.88x^3 - 2.54x^4 + 0.99x^5 \\ + 0.96x^6 - 0.21x^7 - 0.15x^8 + 0.01x^9 + 0.01x^{10}.$$

- **Regressão ridge:**

$$p_{10}^{(R)}(x) = 1.45 + 0.69x + 0.28x^2 + 0.13x^3 + 0.10x^4 + 0.04x^5 \\ + 0.05x^6 - 0.03x^7 - 0.02x^8 + 0.00x^9 + 0.00x^{10}$$

Note que os coeficientes que multiplicam potências de  $x$  são menores na regressão ridge. Em particular, os coeficientes que multiplicam  $x^9$  e  $x^{10}$  são nulos.

- **Regressão Lasso:**

$$\begin{aligned} p_{10}^{(L)}(x) &= 2.05 + 0.00x + 0.00x^2 + 0.00x^3 + 0.00x^4 + 0.04x^5 \\ &\quad + 0.03x^6 + 0.00x^7 + 0.00x^8 + 0.00x^9 + 0.00x^{10} \\ &= 2.05 + 0.04x^5 + 0.03x^6 \end{aligned}$$


Note que os coeficientes de  $x^k$ ,  $1 \leq k \leq 10$ , da regressão lasso também são menores que os coeficientes da regressão tradicional. Além disso, muitos deles são nulos; confirmando a capacidade de seleção de características da regressão lasso.

- **Elastic Net:**


$$\begin{aligned} p_{10}^{(E)}(x) &= 2.00 + 0.00x + 0.00x^2 + 0.07x^3 + 0.03x^4 + 0.03x^5 \\ &\quad + 0.02x^6 + 0.00x^7 - 0.00x^8 + 0.00x^9 + 0.00x^{10} \\ &= 2.00 + 0.07x^3 + 0.03x^4 + 0.03x^5 + 0.02x^6 \end{aligned}$$

Observe que a Elastic Net produziu um polinômio intermediário, entre a regressão ridge e lasso.

A figura abaixo mostra o conjunto de treino e os polinômios ajustados pelas diferentes métodos de regressão.



Analogamente, a figura abaixo mostra o conjunto de teste e os polinômios ajustados.



A tabela abaixo apresenta o RMSE e MAE dos regressores.

|                         | Treino |       | Teste |       |
|-------------------------|--------|-------|-------|-------|
|                         | RMSE   | MAE   | RMSE  | MAE   |
| Reg. Linear Tradicional | 0.377  | 0.267 | 2.975 | 1.631 |
| Regressão Ridge         | 0.487  | 0.371 | 1.817 | 1.202 |
| Regressão Lasso         | 0.881  | 0.696 | 1.138 | 0.888 |
| ElasticNet              | 0.836  | 0.668 | 1.146 | 0.889 |

Note que, com respeito à ambas medidas RMSE e MAE, os regressões podem ser ordenados da seguinte forma no conjunto de treino: Tradicional, Ridge, Lasso e Elastic Net.

Contudo, os mesmos regressores são ordenados da seguinte forma considerando as métricas no conjunto de teste: Lasso, Elastic Net, Ridge e Tradicional.

Esse exemplo confirma a melhora na capacidade de generalização dos modelos regularizados.

# Considerações Finais

---

Na aula de hoje, apresentamos modelos de regressão linear regularizados. Especificamente, vimos os modelos:

1. **Regressão Ridge:** Utiliza a regularização  $\mathcal{R}_2$ . Tal como a regressão usual, a regressão ridge possui uma fórmula fechada obtida das equações normais.
2. **Regressão Lasso:** Utiliza a regularização  $\mathcal{R}_1$ . Apesar de não ser diferenciável, a função perda pode ser minimizada usando métodos baseados no sub-gradiente. A regressão lasso pode também ser usada para seleção de características.
3. **Elastic Net:** Utiliza uma combinação convexa das regularizações  $\mathcal{R}_1$  e  $\mathcal{R}_2$ . A elastic net também pode ser usada para seleção de características e é recomendada quando  $n > m$  ou existem características fortemente correlacionadas.

Muito grato pela atenção!



## References (1)

---

M. Grant, S. Boyd, and Y. Ye. Disciplined Convex Programming. In *Global Optimization*, pages 155–210. Kluwer Academic Publishers, 6 2006. doi: 10.1007/0-387-30528-9{\\_}7.